

Inteligencia de Negocios y Minería de Datos

Ingeniería de Software

Facultad de Ingeniería

Universidad Cooperativa de Colombia

2025



Qué es ETL y su papel en la construcción de una bodega de datos

Definición de ETL

- **Extract:** obtener datos desde fuentes variadas (bases de datos, archivos, APIs).
- **Transform:** limpieza, integración, normalización, reglas de negocio.
- **Load:** almacenar datos preparados en el sistema destino para análisis.


Importancia de planificar correctamente el proceso ETL

- Alinear con los requerimientos del negocio.
- Asegurar calidad de los datos: exactitud, completitud, consistencia.
- Diseñar para escalabilidad y mantenimiento.

Pasos típicos del diseño ETL

- Identificar fuentes de datos relevantes alineadas con objetivos.
- Definir esquemas destino, métricas y dimensiones.
- Establecer reglas de transformación (limpieza, validación, enriquecimiento).
- Planificar carga (batch vs incremental, volúmenes, performance).

Técnicas de ETL



Extract (E): Extracción

1. Métodos de extracción

- **Pull extraction (extracción por demanda)**

El *pipeline* inicia la lectura cuando lo programa (batch/cron/orquestador).

Útil cuando: las fuentes no pueden emitir eventos, ventanas nocturnas, cargas periódicas.

Pros: control total del horario; menor acoplamiento.

Contras: mayor latencia; riesgo de “ventanas perdidas” si hay caídas.


- **Push extraction (extracción por emisión)**

La fuente **empuja** registros nuevos a un *endpoint* o cola (webhook/Kafka).

Útil cuando: se requiere **casi-tiempo real** (clickstream, POS online).

Pros: baja latencia; menor *polling*.

Contras: mayor complejidad operativa; back-pressure y reintentos.



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción

2. Tipos de extracción

- **Full load (completa)**

Trae **todo** el conjunto cada vez.

Cuándo: datasets pequeños, cargas iniciales, auditorías.

Riesgos: tiempo/costo altos; bloqueos; duplicación si no hay idempotencia.

- **Incremental load (incremental)**


Trae **solo lo nuevo o modificado** desde la última corrida (marca de agua).

Cuándo: operaciones diarias; tablas grandes.

Claves: campo `updated_at`, secuencial id, o **CDC** (ver abajo).

Riesgos: *drift* de esquema, *late arriving records*, *soft deletes*.

Regla práctica: primera vez **Full** → siguientes **Incremental** con marca de agua o CDC.



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción


3. Técnicas de extracción

a) Database querying (SQL sobre OLTP/DW)

- Patrón batch incremental:

```
-- Marca de agua basada en updated_at
SELECT *
FROM ventas
WHERE updated_at > :ultima_ejecucion
ORDER BY updated_at;
```

- **Buenas prácticas:** *timeouts*, paginación (LIMIT/OFFSET), columnas explícitas, control de cambios de esquema.



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción

3. Técnicas de extracción


b) File parsing (archivos)

- Fuentes: CSV, Parquet, JSON, Excel.
- Checklist: codificación, delimitador, encabezados, tipos, escape de comillas, archivos vacíos/duplicados, sumas de control.

c) API calls (REST/GraphQL)

- **Temas clave:** rate limits, autenticación (OAuth/token), paginación (page, cursor), webhooks para cambios.
- **Pseudocódigo:**

```
GET /v1/orders?updated_after=2025-09-01T00:00:00Z&page_token=abc123
```



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción


3. Técnicas de extracción

d) Event-based streaming (Kafka/Kinesis/PubSub)

- **Patrón:** la aplicación publica eventos; el *consumer* persiste en *staging*.
- **Cuidar:** orden de mensajes, reintentos idempotentes, esquemas (Avro/JSON) con *schema registry*.

e) Web scraping

- **Usar solo si no hay API.** Respetar *robots.txt*, *backoff*, cambios de DOM.
- **Riesgos:** fragilidad, aspectos legales/éticos.



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>


Extract (E): Extracción

3. Técnicas de extracción

f) CDC – *Change Data Capture*

Captura **inserciones, actualizaciones y borrados** desde la fuente.

- **Timestamp-based:** filtra por `updated_at`. Simple, pero depende de disciplina en la app.
- **Trigger-based:** *triggers* que registran cambios. Preciso, pero intrusivo.
- **Log-based:** lee el *binlog*/redo log del motor (Debezium, Oracle GoldenGate). Escalable y no intrusivo.
- **Borrados (*soft/hard delete*):**
 - *Soft:* bandera `is_deleted`; propagar para de-activar registros en DW.
 - *Hard:* evento DELETE vía CDC log-based.




Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción

3. Técnicas de extracción

g) Manual data extraction

- **One-off** (Excel temporal, export puntual). Control con checksum y data contracts temporales.



Fuente: <https://rihab-feki.medium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Extract (E): Extracción

4) Calidad y gobierno en la extracción

- **Idempotencia:** posibilidad de re-ejecutar sin duplicar. (Claves naturales + upsert en staging).
- **Controles de completitud:** conteos por partición/fecha; sumas de importes; hash por archivo.
- **Metadatos y trazabilidad:** fuente, batch_id, ventana temporal, timestamp de extracción.
- **Gestión de errores:** colas de dead letters, retry exponencial, alertas.
- **Contrato de datos:** versión de esquema, tipado, valores permitidos.

Métricas sugeridas: freshness (min), throughput (reg/s), tasa de error (%), cobertura de campos (% no-nulos).

Extract (E): Extracción

5) Decidir la estrategia (matriz rápida)

Escenario	Método	Tipo	Técnica primaria
POS en 30 tiendas, casi real-time	Push	Incremental	CDC log-based a staging
ERP con corte nocturno	Pull	Incremental	SQL con updated_at
CRM SaaS	Pull/Push	Incremental	API con paginación + webhooks
Ads/Redes	Pull	Incremental	API REST con rate-limit
Históricos iniciales	Pull	Full	Export masivo (CSV/Parquet)

Extract (E): Extracción

6) Ejemplo aplicado (SuperAndes / RetailMax)

- **POS:** CDC log-based → *staging* particionado por `event_date`.
- **ERP:** SQL incremental nocturno por `updated_at`.
- **CRM:** API con cursor y `since` + manejo de *rate-limit*.
- **Marketing digital:** APIs (Google/Meta) → normalización de métricas y *mapping* de campañas.
- **Archivos externos de proveedores:** ingestión de CSV a *landing* con validación de esquema (cabeceras, tipos, nulos).

7) Plantilla de checklist

- Elegir método (**pull/push**) y tipo (**full/incremental**).
- Definir **marca de agua/CDC y borrados**.
- Diseñar **idempotencia** y re-intentos.
- Registrar **metadatos y controles** (conteos, hashes).
- Documentar **contrato de datos** y versión de esquema.
- Establecer **métricas** (freshness, errores, throughput).

Transform (T): Transformar

1) Data Cleansing (limpieza de datos)

Proceso de **depurar y preparar** los datos para que sean útiles, consistentes y confiables.

- **Remove duplicates (eliminar duplicados)**


- Evita registros contados dos veces.
- Ejemplo: cliente “12345” registrado dos veces en CRM.
- Técnica: ROW_NUMBER() OVER(PARTITION BY cliente ORDER BY updated_at DESC) → conservar el más reciente.

- **Data filtering (filtrar datos irrelevantes)**

- Solo extraer las columnas y filas necesarias.
- Ejemplo: excluir transacciones de prueba o campañas canceladas.

- **Handling missing data (gestión de faltantes)**

- Estrategias: imputar (media/mediana/moda), reemplazo por default, eliminación.
- Ejemplo: fecha de nacimiento faltante en CRM → imputar con categoría “desconocido”.



Fuente: <https://rihab-fekimedium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Transform (T): Transformar

1) Data Cleansing (limpieza de datos)

- **Handling invalid values (valores inválidos)**

- Corregir campos fuera de rango o con formato incorrecto.
- Ejemplo: ventas con precio = -100.

- **Outlier detection (detección de atípicos)**


- Identificar valores extremos.
- Ejemplo: un cliente con 10,000 compras en un día.
- Técnicas: z-score, IQR, reglas de negocio.

- **Data type casting (tipado correcto)**

- Asegurar que los campos tienen el tipo correcto (integer, float, date).
- Ejemplo: campo importe en string → convertir a DECIMAL.

- **Handling unwanted spaces (espacios/caracteres no deseados)**

- Limpieza de cadenas: TRIM(), REPLACE().
- Ejemplo: “ Bogotá ” vs “Bogotá”.



Fuente: <https://rihab-fekimedium.com/building-a-modern-data-warehouse-from-scratch-d18d346a7118>

Transform (T): Transformar

2) Data Integration (integración de datos)


- **Combinar fuentes heterogéneas** (ERP, POS, CRM, Marketing).
- Resolver diferencias de esquema, nombres, tipos y claves.
- Ejemplo: unificar "id_cliente" del CRM y "customer_id" del ERP.

3) Data Enrichment (enriquecimiento de datos)

- Añadir información externa o derivada.
- Ejemplo: enriquecer ventas con datos meteorológicos (para analizar impacto del clima).

4) Derived columns (columnas derivadas)

- Nuevos atributos calculados a partir de los existentes.
- Ejemplo:
 - `ingreso_total = cantidad * precio_unitario.`
 - `segmento_edad = CASE WHEN edad BETWEEN 18 AND 25 THEN '18-25' ... END.`




Transform (T): Transformar

5) Data Normalization & Standardization (normalización/estandarización)

- **Normalización:** llevar datos a un rango común.
Ejemplo: escalado 0-1 para comparaciones.
- **Estandarización:** unificar unidades y formatos.
Ejemplo: precios en USD vs COP.

6) Business rules & Logic (reglas de negocio)

- Aplicar la lógica empresarial al dato.
- Ejemplo:
 - Definir “venta válida” = transacción con método de pago aprobado.
 - Definir “cliente activo” = al menos 1 compra en últimos 12 meses.




Transform (T): Transformar

7) Data Aggregations (agregaciones)

- Resumir datos para análisis estratégico.
- Ejemplo: ventas totales por ciudad y mes.

```
SELECT ciudad, DATE_TRUNC('month', fecha) AS mes, SUM(importe) AS total
FROM ventas
GROUP BY ciudad, mes;
```



Transform (T): Transformar


8) Slowly Changing Dimensions (SCD)

Cómo manejar cambios históricos en dimensiones (muy importante en BI):

- **Tipo 0 (sin historización):** no se actualiza.
- **Tipo 1 (sobrescritura):** se reemplaza el valor antiguo (corrige errores).
- **Tipo 2 (historización completa):** se guarda inicio/fin de vigencia.
- **Tipo 3 (valor anterior en columna extra):** guarda versión previa solo en 1 campo.

Ejemplo:

- Cliente cambia de ciudad.
- **SCD1:** ciudad = nueva ciudad.
- **SCD2:** dos filas: Bogotá (vigencia hasta 2024), Medellín (vigencia desde 2025)



Transform (T): Transformar

9) Ejemplo aplicado (SuperAndes / RetailMax)

- **Cleansing:** eliminar duplicados de clientes en CRM.
- **Integration:** unir POS (ventas) con ERP (stock) vía id_producto.
- **Enrichment:** agregar variable “día lluvioso” a ventas.
- **Business logic:** marcar promociones válidas solo si aplican a productos activos.
- **Aggregation:** ventas por categoría y trimestre.
- **SCD:** gestionar cambios de dirección de clientes en CRM (mantener histórico).


10) Checklist de Transform

- Eliminar duplicados y registros irrelevantes.
- Normalizar formatos y tipos de dato.
- Manejar valores faltantes/inválidos.
- Integrar múltiples fuentes con claves unificadas.
- Aplicar reglas de negocio de la organización.
- Derivar columnas útiles para análisis.
- Agregar datos para análisis estratégico.
- Diseñar estrategia SCD para cambios históricos.
- Documentar decisiones de limpieza y transformación.

Load (L): Cargar

1) Processing Types


- **Batch processing (procesamiento por lotes)**
 - Se cargan grandes volúmenes en ventanas definidas (ej. cada noche).
 - **Útil cuando:** los datos no requieren inmediatez.
 - **Ejemplo:** ventas diarias de todas las tiendas → carga nocturna al DW.
- **Stream processing (procesamiento en flujo)**
 - Se cargan los datos casi en tiempo real, registro por registro o en micro-lotes.
 - **Útil cuando:** el negocio necesita monitoreo continuo (fraude, IoT, POS online).
 - **Ejemplo:** detección de patrones de compra sospechosos al instante.



Load (L): Cargar

2) Load Methods

- **Full load (carga completa)**
 - Se borran los datos destino y se reemplazan con los nuevos.
 - Métodos: *truncate + insert*, *drop-create-insert*.
 - **Ventaja:** simple, limpia inconsistencias.
 - **Desventaja:** alto costo; no viable en grandes volúmenes.
- **Incremental load (carga incremental)**
 - Solo se cargan registros nuevos o modificados.
 - Métodos:
 - **Upsert:** actualiza si existe, inserta si no.
 - **Append:** solo inserta, sin actualizaciones.
 - **Merge:** combina lógicas de insert/update/delete.
 - **Ejemplo aplicado:** actualizar inventario diario con nuevas ventas.




Load (L): Cargar

3) Slowly Changing Dimensions (SCD)

Fundamental para manejar cambios en **dimensiones** sin perder trazabilidad histórica.


- **SCD0:** no se actualiza solo la primera versión.
- **SCD1:** sobrescribe se pierde el histórico.
- **SCD2:** guarda historial con fechas de vigencia o bandera is_current.
- **SCD3:** guarda versión anterior en columna adicional (limitado).
- **Ejemplo:**
 - Cliente cambia de ciudad.
 - Con **SCD2**, se conserva Bogotá (2023–2024) y Medellín (2025–).



Load (L): Cargar

4) Ejemplo aplicado (SuperAndes/RetailMax)

- **Batch:** carga nocturna de ERP al DW para reportes de inventario.
- **Stream:** POS transmite ventas en tiempo real, monitoreo de stock.
- **Full load:** al inicio, para poblar DW con históricos de 3 años.
- **Incremental (upsert/merge):** para actualizar clientes y campañas diariamente.
- **SCD2:** para mantener histórico de cambios en direcciones de clientes.



Load (L): Cargar

5) Buenas prácticas de carga

- **Idempotencia:** la misma carga no debe duplicar datos.
- **Particionamiento:** cargar por fecha o región → optimiza queries.
- **Transacciones:** asegurar que una carga es atómica.
- **Validación post-load:** conteo de filas, sumas de control, hashes.
- **Monitoreo y logging:** métricas de tiempo, registros cargados, errores.
- **Rollback:** plan de reversión ante fallas.

6) Checklist de Load

- Elegir tipo de procesamiento (**batch** o **stream**).
- Decidir método de carga (**full** o **incremental**).
- Implementar estrategia **SCD** para dimensiones.
- Asegurar idempotencia (no duplicar cargas).
- Configurar validaciones post-load (conteos, sumas, hashes).
- Monitorear tiempos y errores.
- Documentar reglas de carga y actualización.

Bibliografía

Básica

- **Han, Jiawei; Pei, Jian; Kamber, Micheline.** *Data Mining: Concepts and Techniques*. 4ª ed. Elsevier, 2022.
- **Provost, Foster; Fawcett, Tom.** *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media, reimpresión 2020.
- **Sherman, Rick.** *Business Intelligence Guidebook: From Data Integration to Analytics*. Morgan Kaufmann, 2015.
- **Witten, Ian H.; Frank, Eibe; Hall, Mark A.; Pal, Christopher J.** *Data Mining: Practical Machine Learning Tools and Techniques*. 5ª ed. Morgan Kaufmann, 2016.
- **Curto Díaz, Josep,** *Introducción al Business Intelligence*. Marcombo.

Complementaria

- **Nussbaumer Knaflic, Cole.** *Storytelling with Data: A Data Visualization Guide for Business Professionals*. 2ª ed. Wiley, 2022.
- **Leskovec, Jure; Rajaraman, Anand; Ullman, Jeffrey D.** *Mining of Massive Datasets*. 3ª ed., Cambridge University Press, 2020.